

Projektarbeit

an der Hochschule für Technik und Wirtschaft des Saarlandes
im Studiengang Praktische Informatik
der Fakultät für Ingenieurwissenschaften

Visual Explainable AI: Ein interaktives Tool zur Visualisierung von XAI-Verfahren in der Bildklassifikation

vorgelegt von
Germain Girndt
Katharina Krier
Antonio Metz

betreut und begutachtet von
Prof. Dr. Christoph Tholen

Saarbrücken, 2026

Abstract

Black-Box-Modelle bieten zwar oft eine hohe Vorhersagegüte, sind aber schwer zu interpretieren. In diesem Zusammenhang stellt diese Projektarbeit das interaktive Tool *Visual Explainable AI* vor, das Studierenden Verfahren des Fachgebiets Explainable Artificial Intelligence (XAI) auf einer visuellen Nutzeroberfläche bereitstellt, um die Ergebnisse komplexer neuronaler Netzwerke verständlicher zu machen. *Visual Explainable AI* wurde mit den Best-Practices in der Softwaretechnik entwickelt und bietet in der vorliegenden Version Visualisierungen für die XAI-Methoden Grad-CAM und LIME auf die vortrainierten neuronalen Netzwerke ResNet und EfficientNetV2 an, lässt sich aber aufgrund der implementierten Softwarearchitektur Model-View-Presenter (MVP) mit Supervising Presenter um weitere neuronale Netzwerke und XAI-Verfahren leicht erweitern. Zur Evaluierung der Wirksamkeit des Tools auf Studierende wurde eine Umfrage durchgeführt. Die Ergebnisse zeigten u. A., dass das Tool in der Wahrnehmung der Befragten das Erkennen relevanter Eingabemerkmale sowie potenzieller Fehlvorhersagen und Grenzen von KI-Modellen unterstützt, wobei das Vertrauen in die Modellentscheidungen trotz Nutzung des Tools überwiegend neutral blieb. Weitere Untersuchungen mit repräsentativeren Stichproben sind erforderlich, um die Auswirkungen des Tools umfassender zu bewerten und weitere Möglichkeiten zur Verbesserung seiner Effektivität zu identifizieren.

Inhaltsverzeichnis

1	Einführung	1
2	Grundlagen	3
2.1	ImageNet als Innovationstreiber in der Bildklassifikation	3
2.2	Architekturen für die Bildklassifikation	3
2.2.1	Convolutional Networks	3
2.2.2	Residual Networks	4
2.2.3	EfficientNetV2	5
2.3	XAI-Verfahren	5
2.3.1	Grad-CAM	6
2.3.2	LIME	7
2.3.3	Layerwise Relevance Propagation	7
3	Anforderungen und Analyse	9
3.1	User Story	9
3.2	Anforderungsanalyse	9
3.2.1	Must-Have Anforderungen	9
3.2.2	Should-Have Anforderungen	11
3.2.3	Could-Have Anforderungen	11
3.2.4	Won't-Have Anforderungen	11
3.2.5	Wahl der XAI-Verfahren	12
4	Konzeption	15
4.1	Model-View-Presenter (MVP) mit Supervising Presenter	15
4.1.1	Einleitung in das MVP-Architekturmuster	15
4.1.2	Wahl der Architektur	15
4.2	Statisches Modell	16
4.3	Dynamisches Modell	20
5	Implementierung	23
5.1	Webapplikation als Grafische Benutzeroberfläche	23
5.1.1	Wahl einer Webapplikation	23
5.1.2	GUI-Elemente	23
5.1.3	Interaktion mit der GUI	25
5.2	Built-in Support für Grad-CAM sowie LIME auf EfficientNetV2	25
5.2.1	Implementierung der EfficientNetV2- und ResNet-Modelle	25
5.2.2	Implementierung der XAI-Verfahren	26
6	Fallstudie	27
6.1	Aufbau	27
6.1.1	Demonstration	27
6.1.2	Fragen	28
6.2	Ergebnisse	29
6.2.1	Demografische Auswertung	38
6.2.2	Qualitative Daten	38

6.2.3	Analyse	38
7	Diskussion	41
7.1	Grenzen und Verzerrungen	41
7.1.1	Stichprobengröße	41
7.1.2	Demonstration	41
7.2	Ergebnisse	41
7.2.1	Vergleich vor und nach der Demonstration	41
7.2.2	Schlussfolgerungen	42
7.2.3	Wirksamkeit des Tools	42
7.3	Studienlage	42
7.3.1	Andere Studien	42
8	Fazit und Ausblick	43
	Literatur	45

1 Einführung

In den letzten Jahren hat sich der Einsatz Künstlicher Intelligenz immer weiter verbreitet [2]. Zu den wichtigsten Methoden gehören Deep-Neural-Networks wie zum Beispiel Convolutional Neural Networks (CNNs) und Residual Networks (ResNets). Diese werden unter anderem zur Bildklassifikation eingesetzt und sind mittlerweile in der Lage dazu, Ergebnisse mit sehr hoher Genauigkeit zu erzielen [5, 7, 22].

Ein großer Nachteil dieser Modelle ist allerdings die schlechte Nachvollziehbarkeit der Ergebnisse, wodurch sie auch als „Black-Box-Modelle“ bezeichnet werden. Explainable Artificial Intelligence (XAI) kann daher genutzt werden, um Nutzern KI-Entscheidungen, die auf komplexen Modellen basieren, einfacher darzustellen [6].

Das Ziel dieser Projektarbeit war es, eine interaktive grafische Benutzeroberfläche zu entwickeln, mithilfe derer die Bildklassifikation verständlicher gemacht werden kann. So soll das Tool *Visual Explainable AI* Studierenden den Einstieg in das Fachgebiet *Explainable Artificial Intelligence* erleichtern.

Es wurde zudem eine Fallstudie durchgeführt, die den Einfluss unseres Tools auf Studierende und deren Verständnis der Grenzen von KI-Modellen, sowie die Nachvollziehbarkeit und den Einfluss von XAI Erklärungen untersucht.

In dieser Hinsicht wurde die vorliegende Projektarbeit folgendermaßen strukturiert:

- *Kapitel 2: Grundlagen* erklärt die Grundlagen von neuronalen Netzwerken und XAI.
- *Kapitel 3: Anforderungen und Analyse* beschreibt die Anforderungsanalyse und begründet die getroffenen Entscheidungen bei der Auswahl der vortrainierten CNN-Modelle und der XAI-Verfahren.
- *Kapitel 4: Konzeption* beschreibt das entworfene Softwarekonzept sowie die geplante Systemarchitektur und begründet die getroffenen Entscheidungen.
- *Kapitel 5: Implementierung* bietet einen Überblick über die wichtigsten Entscheidungen bei der Implementierung des Tools.
- *Kapitel 6: Fallstudie* zeigt wie die Fallstudie zur Evaluierung des entwickelten Tools aufgebaut und durchgeführt wurde, sowie die erzielten Ergebnisse.
- *Kapitel 7: Diskussion* evaluiert die Ergebnisse der Fallstudie und diskutiert die Wirksamkeit des Tools.
- *Kapitel 8: Fazit und Ausblick* fasst die wichtigsten Erkenntnisse der Arbeit zusammen.

2 Grundlagen

In den nächsten Abschnitten werden die Grundlagen der Bildklassifikation, der Architekturen für die Bildklassifikation und der XAI-Verfahren vorgestellt, um ein besseres Verständnis für die folgenden Kapitel zu schaffen.

2.1 ImageNet als Innovationstreiber in der Bildklassifikation

Als eine der bekanntesten Daten- und Benchmarking-Quellen in der Bildklassifikation gilt ImageNet, ein Projekt der Universitäten Stanford und Princeton [11]. Im Rahmen dieser Initiative wurden über die Jahre hinweg mehrere Datensätze veröffentlicht, auf denen Forscher ihre Modelle trainiert und getestet haben. Beispielsweise wurden 2009 zirka 3,2 Millionen Bilder zur Verfügung gestellt, die 5.427 Kategorien zugeordnet wurden [3].

Zwischen 2012 und 2017 wurden die sogenannten ImageNet Large Scale Visual Recognition Challenges (ILSVRC) durchgeführt, bei denen Forscher ihre Modelle auf einem standardisierten Datensatz mit 1.281.167 Trainingsbildern, 50.000 Validierungsbildern und 100.000 Testbildern [9] testen und vergleichen konnten [10, 11]. Diese Challenges haben zu bedeutenden Fortschritten in der Bildklassifikation geführt: Forscher erhielten Daten und eine standardisierte Umgebung, in der sie ihre Techniken testen und vergleichen konnten, was zu einem intensiven Wettbewerb führte, in dem viele innovative Architekturen entstanden sind.

2.2 Architekturen für die Bildklassifikation

Mit der zunehmenden Verfügbarkeit von großen Bilddatensätzen und der Entwicklung leistungsfähiger Hardware haben sich Deep-Learning-Modelle als äußerst effektiv für die Bildklassifikation erwiesen [12]. In den folgenden Abschnitten werden einige der wichtigsten Architekturen vorgestellt, die in diesem Bereich verwendet werden.

2.2.1 Convolutional Networks

Im Vergleich zu den klassischen *Feedforward Neural Networks* (FNNs) sind *Convolutional Neural Networks* (CNNs) effizienter: Sie haben eine effiziente Struktur mit weniger Gewichten und Kanten zwischen den Modellschichten etabliert, was das Training erleichtert, ohne dabei einen beträchtlichen Verlust an Leistung zu verursachen [12]. Dadurch eignen sich CNNs besonders gut für die Verarbeitung von Bilddaten, da sie die räumlichen Beziehungen zwischen den Pixeln nutzen können, um relevante Merkmale durch verschiedene Abstraktionsebenen zu extrahieren.

Das sogenannte AlexNet [12] war eines der ersten CNNs, das auf dem ImageNet-Datensatz eine signifikante Verbesserung der Bildklassifikationsleistung erzielte und damit den Durchbruch für CNNs in diesem Bereich markierte. Seitdem wurden viele weitere Architekturen entwickelt, die sich von AlexNet bei der Verwendung von Convolutional Layers inspirieren ließen, wie z. B. VGGNet [20], ResNet [7], MobileNet [8] und EfficientNetV2 [22].

Die nächsten Abschnitte konzentrieren sich auf die Architekturen ResNet und Efficient-NetV2, da sie aufgrund ihrer historischen und technischen Relevanz eine hohe Bedeutung für die Bildklassifikation haben.

2.2.2 Residual Networks

Die Erhöhung der Anzahl der Schichten in einem Deep Neural Network (DNN) war nicht immer mit einer Verbesserung der Vorhersagegüte verbunden. In dieser Hinsicht wurde beobachtet, dass die Erweiterung eines Netzwerks um eine größere Anzahl von Schichten oft zu einer deutlichen Erhöhung der Fehlerrate sowohl beim Training als auch bei Tests führte. So wurde das Phänomen des sogenannten *Degradationsproblems* von [7] wie folgt beschrieben:

Driven by the significance of depth, a question arises: Is learning better networks as easy as stacking more layers? [...]

When deeper networks are able to start converging, a degradation problem has been exposed: with the network depth increasing, accuracy gets saturated (which might be unsurprising) and then degrades rapidly. Unexpectedly, such degradation is not caused by overfitting, and adding more layers to a suitably deep model leads to higher training error, as reported in [10, 41] and thoroughly verified by our experiments.

Dies stellte die wissenschaftliche Gemeinschaft vor ein Rätsel: Falls zusätzliche Schichten nicht zu einer erhöhten Leistung führten, wären sie theoretisch dennoch in der Lage, die Identitätsfunktion zu approximieren, sodass die Leistung des erweiterten Modells zumindest nicht wesentlich schlechter als die des ursprünglichen Modells sein sollte. In der Praxis war dies jedoch häufig nicht der Fall, und die Leistung verschlechterte sich sogar deutlich.

So wurde dieses Problem durch die Einführung sogenannter Residual-Blöcke gelöst [7]. Diese Blöcke enthalten eine direkte Verbindung zwischen der Eingabe und der Ausgabe, sodass die dazwischenliegenden Schichten lediglich die Differenz (d. h. dass **Residuum**) zwischen der Eingabe und der Ausgabe lernen müssen, wie die sogenannte **Residualfunktion** darstellt:

$$y_k = x_k + \mathcal{F}(x_k, \mathcal{W}_k) \quad (2.1)$$

Dabei bezeichnet x_k die Eingabe eines Blocks, $\mathcal{F}(x_k, \mathcal{W}_k)$ die durch die Schichten parametrisierte Residualfunktion und y_k die Ausgabe des Blocks. Dieses Vorgehen ermöglicht es einem Residual-Block, das *Identity Mapping* mit geringer Rechenkomplexität zu realisieren, indem die Eingabe unverändert zur Ausgabe addiert wird.

Dies ist besonders vorteilhaft, wenn die Ausgabe eines Blocks der Eingabe ähnlich ist, da die Schichten dann nur lernen müssen, die Unterschiede zu modellieren, anstatt die gesamte Funktion zu lernen.

ResNets haben in vielen Bildklassifikationswettbewerben hervorragende Ergebnisse erzielt und sind nach wie vor eine der beliebtesten Architekturen für die Bildklassifikation. Im originalen Paper [7] wurde ein 152-Schichten-Deep-Neural-Network vorgestellt, das auf dem ImageNet-Datensatz eine Top-5-Fehlerquote von nur 3,57% erreichte.

2.2.3 EfficientNetV2

EfficientNet ist eine Familie von Convolutional Neural Networks, die eine bessere Leistung bei geringerer Rechenkomplexität erzielen. Das Modell EfficientNetV2, die Nachfolgerversion von EfficientNetV1, hat sich als besonders leistungsfähig erwiesen: Es verfügt über eine Top-1-Genauigkeit von 85,7% auf dem ImageNet-Datensatz sowie ein 3–9 mal schnelleres Trainingsverfahren und 6–8 mal weniger Gewichtsparameter als der Großteil vergleichbarer Neural Networks im damaligen Stand der Technik [22].

Diese Errungenschaft wurde vor allem durch den Einsatz von Automated Machine Learning mittels Neural Architecture Search (NAS) zur Optimierung der Architektur von EfficientNetV2 sowie durch die Einführung von *Fused-MBConv*-Blöcken erreicht [22]. Dabei wurde die Suche nach der besten Kombination von Schichten und Hyperparametern zur Leistungsoptimierung automatisiert. Darüber hinaus hat sich die Verwendung von *Progressive Learning* beim Training – zunächst mit kleineren Bildern und weniger Regularisierung und anschließend mit größeren Bildern und stärkerer Regularisierung – als besonders effektiv erwiesen, um die Trainingszeit zu verkürzen, ohne die Korrekturklassifizierungsrate des Modells zu beeinträchtigen [22].


2.3 XAI-Verfahren

Obwohl Deep Neural Networks (DNNs) eine beeindruckende Leistung bei der Bildklassifikation ermöglichen, sind sie oft als *Black-Box*-Modelle bekannt, da sich ein genaues Verständnis der Vorhersagens- und Entscheidungsprozesse dieser Modelle als schwierig erweist [19].


In diesem Zusammenhang gewinnt das Forschungsfeld der Explainable Artificial Intelligence (XAI) zunehmend an Bedeutung, da es darauf abzielt, Methoden und Techniken zur Interpretierbarkeit und Transparenz von KI-Modellen zu entwickeln, wobei der Mensch als zentraler Fokus im Mittelpunkt steht [19]. So ermöglicht XAI die Identifizierung von Fehlern, die Herstellung von geeignetem Vertrauen und Zutrauen bei Nutzern sowie das Gewinnen von Erkenntnissen über die Funktionsweise von Modellen und Systemen [19].

In den nächsten Abschnitten werden einige der wichtigsten XAI-Verfahren vorgestellt, die in der Bildklassifikation verwendet werden, um die Entscheidungsprozesse von Modellen wie ResNet und EfficientNetV2 besser zu verstehen.


2.3.1 Grad-CAM



(a) Original Image



(c) Grad-CAM 'Cat'



(i) Grad-CAM 'Dog'

Abbildung 2.1: Grad-CAM Visualisierung für zwei Beispiele wie in [19]: für ein Bild eines Hundes und einer Katze (links) visualisiert das Grad-CAM-Verfahren die wichtigsten Regionen bei der Vorhersage von 'Katze' (oben rechts) und 'Hund' (unten rechts) (Bild von [19]).

Das Verfahren Grad-CAM (*Gradient-weighted Class Activation Mapping*) ermöglicht es, die Bereiche eines Bildes zu identifizieren, die für die Vorhersage eines Modells am wichtigsten sind [19]. Es basiert auf der Berechnung von Gradienten, um die Bedeutung der verschiedenen Regionen eines Bildes für die Vorhersage zu bestimmen. Durch die Visualisierung dieser Regionen können Forscher und Anwender besser verstehen, welche Merkmale des Bildes das Modell für seine Entscheidungen verwendet [19].

Grad-CAM kann auf verschiedenen CNNs angewandt werden, insbesondere (1) CNNs mit Fully-Connected-Layers (z. B. VGG), (2) CNNs für strukturierte Ausgaben (z. B. Captioning) und (3) CNNs für Tasks mit multi-modalen Eingaben oder Reinforcement-Learning, ohne das ursprüngliche Modell zu verändern [19].

2.3.2 LIME




Abbildung 2.2: Daten über Patientensymptome und die vorhergesagte Diagnose eines Modells können erklärt werden, indem die wichtigsten Merkmale für die Vorhersage durch LIME identifiziert werden (Bild von [17]).

Im Gegensatz zu Grad-CAM bietet LIME (*Local Interpretable Model-agnostic Explanations*) eine *agnostische* Methode zur Erklärung von Vorhersagen in beliebigen Modellarchitekturen.

Die Idee hinter LIME ist simpel. Die Vorhersage eines Modells für eine bestimmte Eingabe kann durch die Erstellung eines einfachen, interpretierbaren Modells in der Nähe dieser Eingabe approximiert werden. Das einfache Modell kann dann verwendet werden, um die Vorhersage des komplexen Modells zu erklären, indem es die wichtigsten Merkmale identifiziert, die zur Vorhersage beitragen [14, 17].

Dies wird folgendermaßen realisiert: Permutationen der originalen Daten werden erstellt und die Vorhersage des zu erklärenden Modells für diese Variationen berechnet. Die Permutationen sowie die daraus resultierenden Vorhersagen werden dann verwendet, um ein einfaches gewichtetes Modell zu trainieren, das die Vorhersage des komplexen Modells in der Nähe der ursprünglichen Eingabe approximiert. Dieses einfache, lokale Modell wird dann zur Erklärung der ursprünglichen Vorhersage verwendet [14, 17].

2.3.3 Layerwise Relevance Propagation

Layerwise Relevance Propagation (LRP) ist eine visuelle XAI-Technik und bestimmt die Merkmale von bestimmten Eingangsvektoren, die am stärksten zu einem Klassifizierungsergebnis beitragen [13].

LRP definiert den Relevance Measure R über den Inputvektor, sodass der KI-Modell-Output als Summe der Werte von R dargestellt werden kann [13]:

$$f(x) \approx \sum_{d=1}^V R_d$$

Dabei ist f die Forward-Pass-Funktion des KI-Modells, bei LRP wird der Output des Modells in die Summe der relevanten Pixel des Inputs zerlegt, um das zu erreichen, fängt man mit der Relevanz des Output-Knotens an und propagiert iterativ rückwärts durch das KI-Modell [13].

2 Grundlagen




Abbildung 2.3: Erklärungen für die Output Neuronen 'passenger car' [15][Seite 10]

3 Anforderungen und Analyse

3.1 User Story

Aus dem Dokument *Aufgabenbeschreibung* und den Gesprächen mit Prof. Dr. Tholen ergab sich folgende User Story:

As a professor of Applied Artificial Intelligence,
I want a **graphical user interface** that demonstrates **explainable AI (XAI)**,
so I can visually teach how AI models explain their decisions to my students.

Die Hauptstakeholders dieser User Story sind somit:

1. ein Professor der Angewandten Künstlichen Intelligenz, der das Tool in der Lehre einsetzen möchte
2. Studierende, die das Tool zur Unterstützung ihres Lernprozesses verwenden

Durch eine interaktive grafische Benutzeroberfläche (GUI) soll das Verständnis für Explainable AI (XAI) gefördert werden, indem die Funktionsweise und Ergebnisse von XAI-Verfahren auf Black-Box-Modellen visuell dargestellt werden.

3.2 Anforderungsanalyse

Die Anforderungen an das interaktive Tool wurden erhoben, mithilfe der MoSCoW-Technik priorisiert und durch den Stakeholder bestätigt.

In dieser Hinsicht wurden die Anforderungen in folgende Kategorien eingeteilt:

3.2.1 Must-Have Anforderungen

3.2.1.1 MH1 - Graphical User Interface (GUI)

- Die Anwendung muss ein Graphical User Interface für die Interaktion mit dem Nutzer zur Verfügung stellen.
- Akzeptanzkriterien:
 1. Die GUI kann im Browser ausgeführt werden (z. B. Google Chrome, Firefox, Safari).

Warum? Eine GUI bietet eine nutzerfreundliche Interaktion mit der Anwendung und abstrahiert die darunterliegende Codekomplexität. Die Implementierung der GUI als Webanwendung vereinfacht die Entwicklung.

3.2.1.2 MH2 - Bilder laden und anzeigen

- Die Anwendung muss Bilder laden und anzeigen können.
- Akzeptanzkriterien:
 1. Die Anwendung kann lokal gespeicherte Bilder laden.
 2. Die Anwendung kann geladene Bilder direkt im Browser anzeigen.
 3. Die Anwendung unterstützt die Dateiformate jpeg, png und jpg.

Warum? Durch das Laden von lokalen Bildern kann der Professor mit geringem Aufwand von den Studenten ausgewählte Beispiele zeigen.

3.2.1.3 MH3 - Bildklassifizierung

- Die Anwendung muss ein Bild mithilfe eines Neural-Network-Modells klassifizieren können.
- Akzeptanzkriterien:
 1. Für die Klassifizierung wird die EfficientNetV2-Architektur verwendet.
 2. Die 5 Klassen mit der höchsten Wahrscheinlichkeit werden im Frontend angezeigt.

Warum? EfficientNetV2 bietet eine gute Balance aus Genauigkeit und Performance. Aufgrund der geringen Größe von maximal ein paar hundert MB sind EfficientNetV2-Modelle gut für lokal laufende Demos in Echtzeit während einer Vorlesung geeignet.

3.2.1.4 MH4 - Explainable AI (XAI) Heatmap

- Die Anwendung muss für ein klassifiziertes Bild eine Heatmap zur Erklärung generieren können.
- Akzeptanzkriterien:
 1. Die Erklärungen werden mit der Grad-CAM-Methode generiert.
 2. Der Nutzer kann aus den Top-5-Klassen auswählen, für welche Klasse die Heatmap generiert werden soll.
 3. Die Heatmap wird transparent über dem Bild angezeigt.

Warum? Grad-CAM ist weit verbreitet, intuitiv und in Vorlesungen einfach zu zeigen. Es gibt viele verfügbare Ressourcen zum Lernen über Grad-CAM, (z. B. Artikel, YouTube-Videos, ...), wodurch es ein guter erster Schritt ist, um Erklärbarkeit zu visualisieren.

3.2.1.5 MH5 - Wartbarkeit

- Die Anwendung muss einfach zu warten sein.
- Akzeptanzkriterien:
 1. Dokumentation von:
 - a) genutzten Programmiersprachen und Versionen
 - b) Versionen von Abhängigkeiten und Konfigurationsdetails

Warum? Gute Dokumentation stellt sicher, dass Stakeholder wie z. B. Studenten in der Zukunft das System ohne Konfigurationsprobleme reproduzieren und erweitern können.

3.2.2 Should-Have Anforderungen

3.2.2.1 SH1 - Erweiterbarkeit

- Die Anwendung sollte einfach um weitere Modelle und XAI-Methoden zu erweitern sein.
- Akzeptanzkriterien:
 1. Weitere Bildklassifizierungsmodelle (z. B. ResNet) können ausgewählt werden.
 2. Weitere XAI-Methoden (z. B. LIME) können ausgewählt werden.
 3. Die Architektur ist modular aufgebaut, sodass neue Modelle oder Methoden leicht hinzugefügt werden können.
 4. Hat der Nutzer ein Modell ausgewählt, können nur kompatible Methoden ausgewählt werden.

Warum? Erweiterbarkeit ermöglicht es, dass in zukünftigen Projekten neue Modelle oder XAI-Methoden leicht hinzugefügt werden können. Darüber hinaus sind ResNet ein wichtiges Bildklassifizierungsmodell und LIME eine modellagnostische XAI-Methode, mit denen die Studierenden Experimente und Vergleiche mit den anderen Modellen und XAI-Methoden durchführen können. Die Implementierung von ResNet und LIME dient zur Demonstration der Erweiterbarkeit der Architektur.

3.2.3 Could-Have Anforderungen

3.2.3.1 CH1 - Unterstützung für andere Erklärungsarten

- Die Anwendung könnte weitere Erklärungsformate unterstützen.
- Akzeptanzkriterien:
 1. Das System unterstützt:
 - Textbasierte Erklärungen
 - Grafische Erklärungen

Warum? Textuelle oder grafische Ausgaben können das Verständnis und die Zugänglichkeit für verschiedene Lernarten verbessern.

3.2.4 Won't-Have Anforderungen

3.2.4.1 Streaming oder Batch Processing

- Keine Echtzeit- oder Batch-Bildverarbeitung

Warum? Die Architektur wird vereinfacht und der Fokus auf Interaktion mit einzelnen Bildern für die Lehre gelegt.

3.2.4.2 Fortgeschrittene Erklärungsmethoden

- Kein SHAP oder Integrated Gradients
- Keine 3D- oder zeitliche Visualisierungen

Warum? Die Implementierung und Visualisierung dieser Methoden ist komplexer, Grad-CAM und LIME reichen zu Bildungszwecken.

3.2.4.3 Responsive Design

- Keine Responsive Web UI

Warum? Das Tool dient nur zur Verwendung zu Testzwecken und in Vorlesungen und wird nicht öffentlich ausgeliefert. Daher ist die Unterstützung von Tablets und Mobilgeräten im ersten Moment nicht notwendig.

3.2.4.4 Native App Deployment

- Kein Native App Deployment für Desktop oder Mobilgeräte

Warum? Das Deployment einer App würde die Komplexität des Projekts erhöhen, während der Fokus auf Erklärbarkeit von KI liegt. Da der Nutzer über technisches Wissen verfügt, ist er in der Lage, die Start-Skripte auszuführen.

3.2.4.5 Mehrsprachige Benutzeroberfläche

- Die Benutzeroberfläche wird nur auf Englisch verfügbar sein.

Warum? Englisch ist die Standardsprache der meisten KI-Lehrmaterialien und Übersetzungen sind nicht essenziell für einen ersten Release.

3.2.4.6 Docker Container

- Kein Docker Container.

Warum? Obwohl Docker die Reproduzierbarkeit verbessert, würde es die Komplexität bei einer lokal laufenden Anwendung unnötig erhöhen. Da das Tool auf einem einzigen Gerät läuft und Nutzer direkt Abhängigkeiten installieren können, bietet Containerisierung hier wenig praktischen Nutzen.

3.2.5 Wahl der XAI-Verfahren

Als XAI-Verfahren sollen Grad-CAM und LIME verwendet werden. Diese beiden Verfahren gehören zu den beliebtesten XAI-Verfahren und vor allem Grad-CAM wurde seit Mitte 2025 immer beliebter. Aufgrund der Popularität werden diese Verfahren häufig in wissenschaftlichen Papers behandelt und sind gut dokumentiert. Außerdem sind die Methoden mit PyTorch einfach zu implementieren. Mit zwei unterschiedlichen Verfahren lässt sich auch der Unterschied zwischen der modellspezifischen und der modellagnostischen Funktionsweise zeigen. Grad-CAM ist modellspezifisch, da es mit den Gradienten des Neural Networks arbeitet. LIME ist dagegen modellagnostisch und approximiert die Klassifizierung lokal.




Abbildung 3.1: Zeitlicher Verlauf der Suchanfragen zu Grad-CAM im Vergleich zu anderen Methoden

4 Konzeption

4.1 Model-View-Presenter (MVP) mit Supervising Presenter

4.1.1 Einleitung in das MVP-Architekturmuster

Die Explainable-AI-Anwendung muss folgendes können:

1. Bilder laden und anzeigen
2. Bilder mit einem Neural-Network-Modell klassifizieren
3. Erklärungen mit einer XAI-Methode generieren
4. wartbar, erweiterbar und einfach in einer Vorlesung zu zeigen sein

Die MVP-Architektur erfüllt die Anforderungen durch eine klare Trennung ihrer Hauptkomponenten:

- Models: beinhalten die Logik der einzelnen Komponenten wie die Klassifizierung mit einem Neural-Network-Modell und Generierung der Erklärung
- Views: rendern die Anwendung im Browser
- Presenters: bieten Schnittstellen zum Aufruf der Funktionen durch den Nutzer an

4.1.2 Wahl der Architektur

Die MVP-Architektur wurde hauptsächlich gewählt, um die Kriterien zur Wartbarkeit und Erweiterbarkeit mit einer flexiblen und leichtgewichtigen Architektur zu erfüllen.

4.1.2.1 Vorteile von MVP:

- Separation of Concerns: Isoliert Berechnungen, Logik und UI für einfache Wartung
- Erweiterbarkeit: Neue Modelle oder XAI-Methoden können durch Erweiterung der Modell-Schicht hinzugefügt werden.
- Testbarkeit: Model und Presenter können in einem späteren Zeitpunkt mit Unit Tests unabhängig vom View getestet werden.
- Pädagogische Klarheit: Spiegelt konzeptuelle Trennung zwischen Daten, Verarbeitung und Präsentation wider, was nützlich zur Lehre ist

4.1.2.2 Nachteile von MVP:

- etwas mehr Boilerplate-Code (z. B. zusätzliche Klassen für Views und Presenter)
- benötigt disziplinierte Koordination zwischen Komponenten, um „Fat Presenters“ zu vermeiden.

4.1.2.3 MVP ist besser geeignet als MVC

Model-View-Controller (MVC) ist eine einfachere und leichtgewichtige Alternative zu MVP mit weniger Code und weniger Schichten zum Implementieren. Bei diesem Modell reagiert der Controller auf die Nutzereingabe und greift auf das Model zu. Dieses aktualisiert dann den View, wodurch die Änderungen angezeigt werden. [1] Die Vorteile von MVP überwiegen jedoch, vor allem aufgrund der funktionalen Anforderungen der Wartbarkeit und besonders Erweiterbarkeit.

- Views rendern nur die Komponente und sind unabhängig vom Model (kein Data-Binding/Observer)
- Presenter (die den Datenfluss kontrollieren) sind nicht direkt von der Implementierung der Views abhängig und manipulieren Views nicht direkt (hängen stattdessen von einer Abstraktion ab, die auf Nutzereingaben reagiert und Informationen weitergibt)
- Models benachrichtigen Views nicht bei Veränderungen

Deshalb können neue Funktionalitäten (z. B. neue Neural-Network-Modelle oder Erklärungsmethoden) bei MVP durch Vererbung hinzugefügt werden. Bei MVC wäre das aufgrund der höheren Kopplung von Models, Views und Controllern nicht so einfach. Anpassungen des Views würden auch Einfluss auf das Model haben.

4.2 Statisches Modell

Das statische Modell stellt die Klassen der Anwendung mit ihren Attributen und Methoden dar sowie die Beziehungen zwischen ihnen. Die Klassendiagramme wurden auf Basis der Anforderungen erstellt.

4.2.0.1 Klassendiagramm: Koordination durch die Presenter-Klasse

Der Nutzer interagiert mit dem Presenter, der die anderen Klassen koordiniert.




Abbildung 4.1: Klassendiagramm: Koordination durch die Presenter-Klasse

4 Konzeption

4.2.0.2 Klassendiagramm: Beziehung zwischen Models und Views

4.2.0.3 Views

1. ImageView: rendert das Bild
2. PredictionView: rendert das Bild und die Klassifizierung
3. ExplanationView: rendert das Bild, die Klassifizierung und die Erklärung

4.2.0.4 Models




Abbildung 4.2: Klassendiagramm: Beziehung zwischen Models und Views

4 Konzeption

1. Image: repräsentiert das geladene Bild, importiert es mit der statischen Methode `load_from(file)`
2. NeuralNetwork: klassifiziert ein Image und produziert eine Prediction
3. Prediction: beinhaltet die Ausgabe der Klassifizierung (Name, ID und Wahrscheinlichkeit der Klasse)
4. ExplainableAITechnique: nutzt ein NeuralNetwork und dessen Prediction um eine Explanation zu generieren (z. B. via Grad-CAM)
5. Explanation: repräsentiert das Ergebnis des XAI-Prozesses, normalerweise (aber nicht immer) als visuelle Heatmap generiert aus dem NeuralNetwork-Modell und der Prediction

4.3 Dynamisches Modell

Das dynamische Modell stellt die Funktionsaufrufe und Rückgabewerte zwischen dem User und den Klassen dar. Die Sequenzdiagramme wurden auf Basis des statischen Modells und der Anforderungen erstellt.

4.3.0.1 Sequenzdiagramm: Default Use Case



Abbildung 4.3: Sequenzdiagramm: Default Use Case

4 Konzeption

Dieses Sequenzdiagramm stellt die vier Use Cases der Anwendung dar. Der Nutzer ruft immer zuerst die `MainPresenter`-Klasse auf, die dann Funktionen von anderen Klassen aufrufen kann.

- Modell ändern: `MainPresenter` ruft keine weitere Klasse auf
- Bild hochladen: `MainPresenter` ruft `Image` auf, um das Bild zu laden und `ImageView` rendert das Bild.
- Bild klassifizieren: `MainPresenter` ruft `NeuralNetwork` auf, um das Bild zu klassifizieren und `PredictionView` zeigt die Wahrscheinlichkeiten der Klassen an.
- Bild hochladen: `MainPresenter` ruft `ExplainableAITechnique` auf, um eine Erklärung zu generieren und `ExplanationView` zeigt das Bild mit der Erklärung an.

5 Implementierung

5.1 Webapplikation als Grafische Benutzeroberfläche

5.1.1 Wahl einer Webapplikation

Es wurde sich dafür entschieden, die Grafische Benutzeroberfläche (GUI) als Webapplikation zu implementieren. Ein Grund dafür ist die Plattformunabhängigkeit. Da die Anwendung im Browser läuft, kann sie auf allen Betriebssystemen ausgeführt werden. Läuft die Anwendung auf einem Webserver, ist sie auch leicht zugänglich, da keine Installation benötigt wird, was es vereinfacht, sie zu Demonstrationszwecken in Vorlesungen einzusetzen. Es erleichtert auch das Design, das mit HTML-Templates definiert wurde. Zur Implementierung der Webapplikation wurde das Framework FastAPI verwendet und die Templates wurden mit Jinja2 erstellt.

5.1.2 GUI-Elemente

Auf der linken Seite der GUI befinden sich die Buttons „Upload“, „Classify“ und „Explain“, die in den folgenden Abschnitten beschrieben werden.

5.1.2.1 Upload-Button

Durch einen Klick auf den Upload-Button wird ein Bild hochgeladen, das in der Mitte der Seite angezeigt wird.




Abbildung 5.1: Anzeige des hochgeladenen Bildes

5 Implementierung

5.1.2.2 Classify-Button

Das hochgeladene Bild kann dann mit dem Classify-Button klassifiziert werden.




Abbildung 5.2: Anzeige der 5 wahrscheinlichsten Klassen

5.1.2.3 Explain-Button

Durch Klick auf den Explain-Button öffnet sich ein Dialog mit zwei Dropdown-Menüs zur Auswahl einer der 5 wahrscheinlichsten Klassen. Die möglichen Erklärungsarten sind Grad-CAM und LIME. Bei Grad-CAM markieren verschiedene Farben die Relevanz bestimmter Bereiche für die Klassifizierung des Bildes. Bei LIME wird nur in einer Farbe angezeigt, welcher Bereich für die Klassifizierung relevant war.



Abbildung 5.3: Anzeige der Grad-CAM-Heatmap über dem Bild



Abbildung 5.4: Anzeige des LIME-Overlays über dem Bild
Darüber hinaus können das Modell zur Klassifizierung und die Erklärungsart jeweils mit dem Model-Button und mit dem Process-Button ausgewählt werden.

5.1.3 Interaktion mit der GUI

Das Layout der Seite wird über HTML-Templates definiert. Die Buttons zum Hochladen und Klassifizieren werden immer angezeigt. Der Upload-Button ist ein `<input>`-Element, mit dem eine Datei ausgewählt werden kann. Das Element befindet sich in einem `<form>`-Element, so dass beim Auswählen einer Datei diese in einer POST-Request an die URL `/upload` gesendet wird. Ein weiteres `<form>`-Element enthält ein verstecktes `<input>`-Element, das als value die URL des hochgeladenen Bildes hat und ein `<button>`-Element, über das eine POST-Request an `/classify` gesendet wird. Diese sendet durch das `<input>`-Elements die URL des Bildes an den Server.

5.2 Built-in Support für Grad-CAM sowie LIME auf EfficientNetV2

5.2.1 Implementierung der EfficientNetV2- und ResNet-Modelle

Als CNN-Modell wurden ein vortrainiertes EfficientNetV2 und ein ResNet-Modell verwendet. Diese können – wie viele andere Modelle – über die Library `torchvision` verwendet werden.

EfficientNetV2 ist in den Größen L, M und S verfügbar, hier wird das Modell in Größe L genutzt. Mit einer Acc@1 von 85,8% und einer Acc@5 von 97,8% ist es eines der genauesten Netze und mit 118,5 Millionen Parametern deutlich kleiner als Modelle mit ähnlicher Genauigkeit (Regnet_Y_128GF hat 644,8 Millionen Parameter). Das macht es zu einem sehr effizienten Netz bei hoher Genauigkeit. Der Speicherbedarf ist nicht zu hoch und bei einer Demonstration in einer Vorlesung hat es den Vorteil, dass das Netz nicht mehr trainiert werden muss und die Klassifizierung schnell abgeschlossen ist. Für ResNet gibt es vier verschiedene Größen, die XAI-Anwendung verwendet das größte Modell ResNet152. Es ist mit nur 60,2 Millionen Parameter ein kleineres und effizienteres Netz als EfficientNetV2. Mit 82,3% Acc@1 und 96,0% Acc@5 ist es deshalb auch etwas ungenauer. [16] Durch die Wahl der beiden Netze lässt sich ein Vergleich der Effizienz und Genauigkeit zwischen Netzen unterschiedlicher Größe aufstellen.

5.2.2 Implementierung der XAI-Verfahren

Für die Implementierung der XAI-Methoden gibt es die Klasse `ExplainableAITechnique` mit der Methode `explain`. Diese bekommt als Parameter eine `Prediction`, bestehend aus ID, Name und Wahrscheinlichkeit einer Klasse, sowie ein `NeuralNetwork`-Modell und wird in den Unterklassen `GradCAM` und `LIME` von der jeweiligen Methode implementiert. Für die Berechnungen werden bei beiden Methoden die Bibliotheken `numpy` und `torch` verwendet, für die Bildverarbeitung `PIL`.

5.2.2.1 Grad-CAM

Zur Generierung einer Grad-CAM-Erklärung wird zuerst die letzte Convolutional Layer des Netzes gefunden. Dort wird dann eine Forward-Hook zum Speichern der Aktivierungen und eine Backward-Hook zum Speichern der Gradienten erstellt. Dann wird ein Forward Pass und ein Backward Pass durchgeführt, wodurch die Hooks ausgelöst werden. Die Gewichte der Filter werden anhand des Mittelwertes der Gradienten berechnet und mit ihnen die gewichtete Summe der Feature Maps gebildet, wodurch ein 2D-Array entsteht. Daraufhin wird noch eine ReLU-Funktion angewendet und eine Normalisierung durchgeführt, damit sich alle Werte zwischen 0 und 1 befinden. Das 2D-Array wird schließlich mit der Funktion `cm` von `matplotlib` in eine Heatmap umgewandelt und transparent über das Bild gelegt.

5.2.2.2 LIME

Eine Erklärung für LIME kann mit der Funktion `explain_instance` der `lime`-Bibliothek erzeugt werden. Diese erhält als Eingabe unter anderem das Bild, die Klassifizierungsfunktion und die Anzahl der zufällig veränderten Bilder, die in diesem Fall auf 100 gesetzt ist. Die Klassifizierungsfunktion `lime_predict` gibt anhand eines Arrays von leicht veränderten Bildern die Klassenwahrscheinlichkeiten für jedes Bild zurück. Über den Parameter `segmentation_fn` wird hier festgelegt, dass das Bild in 30 Segmente aufgeteilt wird. Die Funktion `get_image_and_mask` bestimmt, dass die 3 wichtigsten Segmente für die Klassifizierung eingefärbt werden. Am Ende wird dann ein transparentes Overlay, bei dem diese Segmente rot gefärbt sind, über das Bild gelegt.

6 Fallstudie

Im Rahmen der Projektarbeit wurde eine Fallstudie durchgeführt, um die Auswirkungen von XAI zu untersuchen. Das Ziel der Fallstudie war es, die Auswirkung unserer Webanwendung, die die Erklärungsarten Grad-CAM und LIME implementiert, zu untersuchen. So wurde eine Umfrage in der Vorlesung *Einführung in die Grundlagen der Künstlichen Intelligenz* durchgeführt, um die Auswirkungen der Anwendung auf das Verständnis von KI-Modellen zur Bildklassifizierung zu untersuchen. Die Umfrageteilnehmer waren Studierende des Studiengangs Praktische Informatik, was der Zielgruppe oder den Stakeholdern dieser Anwendung entspricht.

6.1 Aufbau

Die Umfrage wurde in zwei Teile aufgeteilt, die jeweils vor und nach der Demonstration der Anwendung beantwortet wurden. So wurde für die Umfrage folgender Aufbau gewählt:

1. Demonstration eines Beispiels für Bildklassifizierung zur Kontextualisierung
2. Beantworten der Fragen 1 bis 8 durch die Studierenden
3. Demonstration der entwickelten App „Visual Explainable AI“
4. Beantworten der Fragen 9 bis 15 durch die Studierenden

Die Umfrage wurde mit Hilfe der Webseite UmfrageOnline erstellt.

6.1.1 Demonstration

In der Demonstration wird das Model EfficientNetV2 benutzt und insgesamt 4 Bilder mit Grad-CAM und LIME klassifiziert. Davon werden zwei Bilder richtig klassifiziert und zwei Bilder falsch.

6.1.1.1 Korrekt klassifizierte Bilder



Abbildung 6.1: Korrekt von EfficientNetV2 klassifizierte Bilder

6.1.1.2 Inkorrekt klassifizierte Bilder




Abbildung 6.2: Inkorrekt von EfficientNetV2 klassifizierte Bilder

6.1.2 Fragen

Die Fragen lassen sich in folgende Kategorien unterteilen

1. demografische Fragen
2. Vorkenntnisse allgemein und KI
3. Verständnis von Gründen der KI für Bildklassifikation vor der Demonstration
4. Verständnis von Gründen der KI für Bildklassifikation nach der Demonstration
5. Bemerkungen

Die Antwortmöglichkeiten sind in eckigen Klammern hinter der Frage angegeben.

Keine Erfahrung Anfänger Fortgeschrittener Anfänger Kompetent Sehr kompetent Experte

Abbildung 6.3: Antwortmöglichkeiten, abgekürzt mit [Erfahrung]

Stimme überhaupt nicht zu Stimme nicht zu Weder Zustimmung noch Ablehnung Stimme zu Stimme voll und ganz zu

Abbildung 6.4: Antwortmöglichkeiten, abgekürzt mit [Zustimmung]

6.1.2.1 Demografische Fragen

1. Alter [numerisch]
2. Geschlecht [männlich, weiblich, n.a.]
3. Studiengang [Freitext]
4. Berufliche Erfahrung [Keine, < 6 Monate, 6-12 Monate, 1-2 Jahre, 2-3 Jahre, > 3 Jahre]

6.1.2.2 Vorkenntnisse allgemein und KI

Fragen 1 bis 5 befassen sich mit den Vorkenntnissen.

1. Bewerten Sie Ihre Kenntnisse und Erfahrungen im Bereich „Künstliche Intelligenz“ [Erfahrung]
2. Bewerten Sie Ihre Kenntnisse und Erfahrungen im Bereich „Maschinelles Lernen zur Bildklassifizierung“ [Erfahrung]
3. Ich bin daran interessiert, etwas über Künstliche Intelligenz zu lernen [Zustimmung]
4. Ich beschäftige mich mit Künstlicher Intelligenz, nur wenn ich dazu verpflichtet bin [Zustimmung]
5. Haben Sie Vorkenntnisse in folgenden Technologien? [neuronale Netzwerke (allgemein), neuronale Netzwerke (spezifisch für Bildklassifizierung), Grad-CAM, LIME, anderweitige XAI Techniken]

6.1.2.3 Verständnis der KI für Bildklassifikation vor der Demonstration

Fragen 6 bis 8 befassen sich mit der Selbsteinschätzung zum Verständnis von Gründen der KI für Bildklassifikation vor der Demonstration der XAI-Anwendung.

6. Ich verstehe, wie ein KI-Modell zur Bildklassifizierung seine Vorhersagen trifft [Zustimmung]
7. Ich verstehe die Grenzen eines KI-Modells zur Bildklassifizierung [Zustimmung]
8. Ich kann erklären, warum ein KI-Modell zur Bildklassifizierung eine Eingabe auf eine bestimmte Weise klassifiziert hat [Zustimmung]

6.1.2.4 Verständnis der KI für Bildklassifikation nach der Demonstration

Fragen 9 bis 15 befassen sich mit der Selbsteinschätzung zum Verständnis von Gründen der KI für Bildklassifikation nach der Demonstration der XAI-Anwendung.


9. Das Tool hat mir geholfen, das Verhalten des Modells besser zu verstehen [Zustimmung]
10. Ich kann anhand der Visualisierungen erkennen, welche Eingabemerkmale für die Modellentscheidung relevant waren. [Zustimmung]
11. Die Erklärungen haben meine Fähigkeit verbessert, KI-Vorhersagen kritisch zu beurteilen [Zustimmung]
12. Das Tool hat mir geholfen zu erkennen, wann das Modell möglicherweise falsche Vorhersagen trifft [Zustimmung]
13. Das Tool hat mir geholfen, die Grenzen von KI-Modellen besser zu erkennen [Zustimmung]
14. Ich verstehe besser den Unterschied zwischen der Genauigkeit eines Modells und seiner Interpretierbarkeit [Zustimmung]
15. Ich vertraue der Entscheidung des KI-Modells, nachdem ich das Tool gesehen habe [Zustimmung]

6.2 Ergebnisse

Im Folgenden sind die Ergebnisse der Umfrage:


Wie viel berufliche Erfahrung* haben Sie insgesamt im Bereich „Informatik“?

Anzahl Antworten: 7




1) Bewerten Sie Ihre Kenntnisse und Erfahrungen im Bereich „Künstliche Intelligenz“.

Anzahl Antworten: 7




2) Bewerten Sie Ihre Kenntnisse und Erfahrungen im Bereich „Machinelles Lernen zur Bildklassifizierung“.

Anzahl Antworten: 7




3) Ich bin daran interessiert, etwas über künstliche Intelligenz zu lernen.

Anzahl Antworten: 7




4) Ich beschäftige mich mit künstlicher Intelligenz, nur wenn ich dazu verpflichtet bin

Anzahl Antworten: 7




5) Haben Sie Vorkenntnisse in folgenden Technologien?

Anzahl Antworten: 6




6) Ich verstehe, wie ein KI-Modell zur Bildklassifizierung seine Vorhersagen trifft.

Anzahl Antworten: 7




7) Ich verstehe die Grenzen eines KI-Modells zur Bildklassifizierung.

Anzahl Antworten: 7




8) Ich kann erklären, warum ein KI-Modell zur Bildklassifizierung eine Eingabe auf eine bestimmte Weise klassifiziert hat.

Anzahl Antworten: 7




9) Das Tool hat mir geholfen, das Verhalten des Modells besser zu verstehen.

Anzahl Antworten: 7




10) Ich kann anhand der Visualisierungen erkennen, welche Eingabemerkmale für die Modellentscheidung relevant waren.

Anzahl Antworten: 7




11) Die Erklärungen haben meine Fähigkeit verbessert, KI-Vorhersagen kritisch zu beurteilen.

Anzahl Antworten: 7




12) Das Tool hat mir geholfen zu erkennen, wann das Modell möglicherweise falsche Vorhersagen trifft.

Anzahl Antworten: 7




13) Das Tool hat mir geholfen, die Grenzen von KI-Modellen besser zu erkennen.

Anzahl Antworten: 7




14) Ich verstehe besser den Unterschied zwischen der Genauigkeit eines Modells und seiner Interpretierbarkeit.

Anzahl Antworten: 6



15) Ich vertraue der Entscheidung des KI-Modells, nachdem ich das Tool gesehen habe.

Anzahl Antworten: 6



Haben Sie weitere Bemerkungen zum Tool?

6.2.1 Demografische Auswertung

Sieben Teilnehmer haben an der Umfrage teilgenommen, davon ein Professor und sechs Studenten. Ein Student kam erst während der Demopräsentation dazu, er wird daher nicht näher betrachtet, da es die Fallstudie verfälschen könnte.

Es gibt also fünf verwertbare Teilnehmer, die Studenten sind. Diese sind zwischen 21 und 33 Jahre alt. Vier Teilnehmer sind Männer, ein Teilnehmer ist eine Frau.

Alle Studenten sind im Studiengang Praktische Informatik.

6.2.2 Qualitative Daten

Die Studienteilnehmer waren Anfänger oder fortgeschrittene Anfänger in KI und Machine Learning für Bilderkennung. Darüber hinaus sind die meisten an XAI interessiert und haben sich positiv gegenüber der Möglichkeit geäußert, über Visualisierungen zu erkennen, welche Eingabemerkmale für die Modellentscheidung relevant waren.

Obwohl die meisten neutral gegenüber [s. Frage 11] waren, haben die meisten den Aussagen [s. Frage 12] und [s. Frage 13] zugestimmt.

Die Antworten waren neutral zu [s. Frage 14].

Die Antworten waren Neutral oder negativ zu [s. Frage 15].

Es gab zwei Bemerkungen:

‘Wenn das Tool als Industrielle anwendung oder Nutzeranwendung geplant ist, wäre eine Moderne Web ui zu empfehlen. Zusätzlich wären weitere Metriken die zur ermittlung warum die KI die entscheidung getroffen hat interessant. Die auswahl verschiedener Modelle sowie weitere Statistiken.’

‘Bei Missinterpretation wäre eine etwas präzisere Erklärung vorteilhaft!’

6.2.3 Analyse

Die Frage [s. Frage 14] wurde nicht genau verstanden. Die Teilnehmer wussten wohl nicht, was genau Interpretierbarkeit und Genauigkeit in Hinsicht auf KI-Modelle sind. Daher waren die Antworten vorwiegend Neutral. Die Auswahl verschiedener Modelle war außerdem möglich, wir haben es nur nicht in der Demo gezeigt.

Das Tool hilft den Teilnehmer dabei, die Grenzen von KI-Modellen zu erkennen, sowie zu erkennen, wann das KI-Modell möglicherweise falsche Entscheidungen trifft. Die allgemeine Fähigkeit KI-Modelle kritisch zu beurteilen wurde dennoch nach der Umfrage nicht verbessert.

Zudem war das Vertrauen in die Entscheidung des KI-Modells neutral bleibend bis gesunken, wahrscheinlich durch die Wahl der zu klassifizierenden Bildern, da zwei davon falsch klassifiziert wurden.

6.2.3.1 Bemerkungen

Das Tool ist nicht als Industrielle Anwendung oder Nutzeranwendung geplant, sondern als Anwendung zum Zeigen von XAI-Methoden im Studium, eine moderne UI wäre vorteilhaft, aber im Rahmen dieser Projektarbeit nicht realistisch.

Da Grad-CAM und LIME visuell über Heatmaps oder Bereiche funktionieren, war es schwer zu erkennen, wieso das Modell misklassifiziert hat. Diese Erklärung wurde nach den Bemerkungen als mangelhaft angesehen.

Grad-CAM und LIME liefern also eine visuelle Erklärung wieso das Modell das Bild einer Klasse zugeordnet hat, es liefert keine eindeutige Erklärung wieso etwas inkorrekt klassifiziert wurde.

Die Antworten waren ziemlich homogen, wahrscheinlich weil die Zielgruppe auch homogen war, also PI-Studierende, die einen ähnlichen Hintergrund haben.

7 Diskussion

Im Folgenden werden die Ergebnisse der Fallstudie evaluiert und die Wirksamkeit des Tools diskutiert.

7.1 Grenzen und Verzerrungen

7.1.1 Stichprobengröße

Es gab nur 5 verwertbare Umfragebögen, Stand WS 2023/2024 gab es im Studiengang Praktische Informatik 303 und im Studiengang Kommunikationsinformatik 124 Studierende [21]. 5 davon sind unter 1 Prozent.

Die Repräsentativität einer Stichprobe ist, wie unverzerrt die Merkmalszusammensetzung in der Stichprobe die Merkmalszusammensetzung in der Zielgruppe widerspiegelt [4][S. 198]. Nicht alle Studierende dieser Studiengänge belegen *Einführung in die Grundlagen der Künstlichen Intelligenz* und nur ein Teil dieser Studierenden nehmen regelmäßig an der Vorlesung, während der die Umfrage stattfand, teil. Die Umfrage ist nicht unbedingt repräsentativ für alle Studenten im Studiengang Praktische Informatik und Kommunikationsinformatik, aber spiegelt Studenten, die *Einführung in die Grundlagen der Künstlichen Intelligenz* und regelmäßig die Vorlesung besucht gut dar, dadurch waren die Ergebnisse der Umfrage auch ziemlich homogen.

7.1.2 Demonstration

7.1.2.1 KI-Modell

In der Demonstration wurde EfficientNetV2 benutzt, es hat eine gute Performance dafür, dass es auf einem Laptop ausgeführt wurde. Leistungsstärkere Modelle klassifizieren Objekte öfter korrekt, aber sind für eine Demonstration auf einem Laptop nicht realistisch. Leistungsschwächere Modelle klassifizieren öfter falsch. Beide Arten können Fragen zum Vertrauen in KI-Modelle oder das Erkennen von Grenzen verzerren.

7.1.2.2 Beispiele

Es wurden zwei korrekt klassifizierte Bilder und zwei inkorrekt klassifizierte Bilder gezeigt, das hat wahrscheinlich die Antworten in Hinsicht zum Vertrauen in dieses KI-Modell und das Erkennen von Grenzen beeinflusst. Inkorrekt klassifizierte Bilder mindern das Vertrauen, wenn die Erklärung nicht für Menschen nachvollziehbar ist, aber zeigen auch, dass KI-Modelle Grenzen haben.

7.2 Ergebnisse

7.2.1 Vergleich vor und nach der Demonstration

Das Tool Visual Explainable AI hat nach der Umfrage den Teilnehmern geholfen im Vergleich zu vor der Demonstration, die Modellentscheidung durch die Visualisierung zu

verstehen [s. Frage 9] und zu erkennen welche Eingabemerkmale für die Klassifizierung relevant waren [s. Frage 10]. Das Tool hat außerdem geholfen zu erkennen, wann das KI-Modell möglicherweise falsche Vorhersagen trifft [s. Frage 12] und zeigt Grenzen des KI-Modells auf[s. Frage 13].

7.2.2 Schlussfolgerungen

Das Tool Visual Explainable AI hat den Teilnehmern der Fallstudie dabei geholfen zu erkennen welche Eingabemerkmale relevant für eine Entscheidung waren, da Grad-CAM und LIME visuell funktionieren, werden so auf einen Blick die für die Klassifizierung relevanten Bereiche sichtbar.

Das ist kritisch, wenn das Bild falsch klassifiziert wird oder die Eingabemerkmale nicht das zu klassifizierende Objekt sind, sondern objektiv irrelevante Bereiche. Das Tool liefert also keine ausreichende Erklärung, warum etwas falsch klassifiziert wurde oder warum diese Eingabemerkmale genau relevant sind.

Es kann anscheinend mit falschen Klassifizierungen auch das Vertrauen in KI-Modelle verringern, was aber auch mit der Auswahl von EfficientNetV2 zu tun haben könnte, da auch bessere KI-Modelle mit einer geringeren Fehlerrate existieren. Es wurden auch zwei richtig klassifizierte Bilder und zwei falsch klassifizierte Bilder gezeigt, was den Eindruck von dem KI-Modell verzerrt.

7.2.3 Wirksamkeit des Tools

Das Tool veranschaulicht die visuellen Erklärmethoden Grad-CAM und LIME. Dadurch wird den Studierenden ein Einstieg in das Gebiet XAI erleichtert, indem sie die Erklärungen für mehrere Klassifizierungsklassen anschauen können. Das Tool hat daher den Zweck einer Einführung in XAI erfüllt .

7.3 Studienlage

7.3.1 Andere Studien

7.3.1.1 Mangelnde Interpretierbarkeit

XAI zeigt welche Features und Muster wichtig für die interne KI-Modell-Entscheidung sind. Diese Muster ergeben aber nicht unbedingt Sinn aus der Sicht eines Menschen [23]. So kann beispielsweise eine Heatmap, die durch LRP erstellt wurde, einen amorphen Blob oder zufällige Pixel highlighten [18], was für Menschen nicht interpretierbar sein könnte. Darüber hinaus können je nach ausgewähltem Netz die erzeugten Erklärungen besser oder schlechter interpretierbar durch Menschen sein[23].

8 Fazit und Ausblick

Diese Projektarbeit hatte zum Ziel, eine interaktive grafische Benutzeroberfläche zu entwickeln, die die Bildklassifikation verständlicher macht. Durch das Tool *Visual Explainable AI* sollte Studierenden der Einstieg in das Fachgebiet *Explainable Artificial Intelligence* erleichtert werden.

Zu diesem Zweck wurden Anforderungen anhand User Stories und engen Gesprächen mit dem Hauptverantwortlichen erhoben und begründet analysiert. Daraus sind unter Anwendung der Moscow-Methode fünf Must-Have-, eine Should-Have-, eine Could-Have- und sechs Won't-Have-Anforderungen entstanden, die zur Erstellung des Softwarekonzepts verwendet wurden, das durch die statischen und dynamischen Modelle beschrieben wird.

So wurde das Tool *Visual Explainable AI* implementiert. *Visual Explainable AI* verwendet Technologien wie Python, FastAPI und PyTorch in Form einer Webapplikation zur Erzeugung von Vorhersagen (mit EfficientNetV2 und ResNet) und Erklärungen (Grad-CAM und LIME) für die Bildklassifikation.

Die Webanwendung setzt die definierten Must-Have-, Should-Have- und Could-Have-Anforderungen erfolgreich um: Sie verfügt über eine grafische Benutzeroberfläche, die es den Nutzern ermöglicht, Bilder hochzuladen, Vorhersagen zu erhalten und die Erklärungen für diese Vorhersagen zu visualisieren. Darüber hinaus ist das Tool wartbar und durch die MVP-Architektur leicht erweiterbar um weitere Neuronale Netze sowie Erklärungsverfahren, die sowohl textbasierte als auch grafische Erklärungen bieten.

Zur Evaluierung des Tools wurde eine Fallstudie durchgeführt, die den Einfluss unseres Tools auf Studierende und deren Verständnis der Grenzen von KI-Modellen, sowie die Nachvollziehbarkeit und den Einfluss von XAI Erklärungen untersucht. Die Ergebnisse der Fallstudie deuten darauf hin, dass die Mehrheit der Teilnehmer ein besseres Verständnis für die Bedeutung von XAI-Erklärungen durch die Anwendung des Tools entwickelt haben könnte. Aufgrund der geringen Teilnehmerzahl können jedoch keine endgültigen Schlussfolgerungen gezogen werden.

Alles in allem wurden die Ziele dieser Projektarbeit erreicht, da das Tool *Visual Explainable AI* erfolgreich implementiert wurde. Die Ergebnisse der Evaluation der Auswirkungen des Tools auf das Verständnis von KI-Modellen durch Studierende sind vielversprechend, jedoch sind weitere Untersuchungen mit einer größeren Teilnehmerzahl erforderlich, um diese Ergebnisse zu bestätigen.

Literatur

- [1] Baeldung. *Difference Between MVC and MVP Patterns*. URL: <https://www.baeldung.com/mvc-vs-mvp-pattern> (besucht am 29.03.2026).
- [2] ChatGPT Record. <https://www.reuters.com/technology/chatgpt-sets-record-fastest-growing-user-base-analyst-note-2023-02-01/>. Accessed: 2025-03-28.
- [3] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li und Li Fei-Fei. „ImageNet: A large-scale hierarchical image database“. In: *2009 IEEE Conference on Computer Vision and Pattern Recognition*. 2009, S. 248–255. DOI: 10.1109/CVPR.2009.5206848. URL: https://image-net.org/static_files/papers/imagenet_cvpr09.pdf.
- [4] Nicola Döring. „Empirische Sozialforschung im Überblick“. In: *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. 2023. ISBN: 978-3-662-64762-2. DOI: 10.1007/978-3-662-64762-2_1. URL: https://doi.org/10.1007/978-3-662-64762-2_1.
- [5] Paolo Giudici, Alex Gramegna und Emanuela Raffinetti. „Machine Learning Classification Model Comparison“. In: *Socio-Economic Planning Sciences* 87 (2023), S. 101560. ISSN: 0038-0121. DOI: <https://doi.org/10.1016/j.seps.2023.101560>. URL: <https://www.sciencedirect.com/science/article/pii/S0038012123000605>.
- [6] Vikas Hassija, Vinay Chamola, Atmesh Mahapatra, Abhinandan Singal, Divyansh Goel, Kaizhu Huang, Simone Scardapane, Indro Spinelli, Mufti Mahmud und Amir Hussain. „Interpreting Black-Box Models: A Review on Explainable Artificial Intelligence“. In: *Cognitive Computation* 16 (Aug. 2023). DOI: 10.1007/s12559-023-10179-8.
- [7] Kaiming He, Xiangyu Zhang, Shaoqing Ren und Jian Sun. „Deep Residual Learning for Image Recognition“. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Las Vegas, NV, USA: IEEE, 2016, S. 770–778. DOI: 10.1109/CVPR.2016.90.
- [8] Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto und Hartwig Adam. *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. 2017. arXiv: 1704.04861 [cs.CV]. URL: <https://arxiv.org/abs/1704.04861>.
- [9] ImageNet. *ImageNet Download*. URL: <https://image-net.org/download.php> (besucht am 20.03.2026).
- [10] ImageNet. *ImageNet Large Scale Visual Recognition Challenge (ILSVRC)*. URL: <https://image-net.org/challenges/LSVRC/index.php> (besucht am 20.03.2026).
- [11] ImageNet. *ImageNet*. URL: <https://image-net.org/index.php> (besucht am 20.03.2026).
- [12] Alex Krizhevsky, Ilya Sutskever und Geoffrey E. Hinton. „ImageNet classification with deep convolutional neural networks“. In: *Proceedings of the 26th International Conference on Neural Information Processing Systems - Volume 1. NIPS’12*. Lake Tahoe, Nevada: Curran Associates Inc., 2012, 1097–1105.

- [13] LRP. <https://danshiebler.com/2017-04-16-deep-taylor-lrp/>. Accessed: 2025-03-23.
- [14] Christoph Molnar. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Munich, Germany: Christoph Molnar, 2022. ISBN: 9798411463330. URL: <https://christophm.github.io/interpretable-ml-book/>.
- [15] Grégoire Montavon, Alexander Binder, Sebastian Lapuschkin, Wojciech Samek und Klaus-Robert Müller. „Layer-Wise Relevance Propagation: An Overview“. In: Hrsg. von Wojciech Samek, Grégoire Montavon, Andrea Vedaldi, Lars Kai Hansen und Klaus-Robert Müller. 2019. ISBN: 978-3-030-28954-6. DOI: 10.1007/978-3-030-28954-6_10. URL: https://doi.org/10.1007/978-3-030-28954-6_10.
- [16] PyTorch. *Models and pre-trained weights*. URL: <https://docs.pytorch.org/vision/stable/models.html> (besucht am 21.03.2026).
- [17] Marco Tulio Ribeiro, Sameer Singh und Carlos Guestrin. „Why Should I Trust You?“. *Explaining the Predictions of Any Classifier*. 2016. arXiv: 1602.04938 [cs.LG]. URL: <https://arxiv.org/abs/1602.04938>.
- [18] Cynthia Rudin. „Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead“. In: *Nature Machine Intelligence* 1 (Mai 2019), S. 206–215. DOI: 10.1038/s42256-019-0048-x.
- [19] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh und Dhruv Batra. „Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization“. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. Venice, Italy: IEEE, 2017, S. 618–626. DOI: 10.1109/ICCV.2017.74.
- [20] Karen Simonyan und Andrew Zisserman. *Very Deep Convolutional Networks for Large-Scale Image Recognition*. Version v6. 2015. arXiv: 1409.1556 [cs.CV]. URL: <https://arxiv.org/abs/1409.1556>.
- [21] *Studierende htw-saar 2023/2024*. https://www.htwsaar.de/fileadmin/studium-und-lehre/im-studium/statistiken/studierende_htw-saar_wise_2023-24_final.pdf. Accessed: 2025-03-21.
- [22] Mingxing Tan und Quoc V. Le. „EfficientNetV2: Smaller Models and Faster Training“. In: *arXiv preprint* (2021). DOI: 10.48550/arXiv.2104.00298. arXiv: 2104.00298 [cs.CV].
- [23] Carlos Zednik und Philippe Verreault-Julien. „Can XAI Justify?“ In: *Philosophy of Science for Machine Learning: Core Issues and New Perspectives*. Springer Nature Switzerland, 2026. ISBN: 978-3-032-03083-2. DOI: 10.1007/978-3-032-03083-2_6. URL: https://doi.org/10.1007/978-3-032-03083-2_6.

Anhang

